Embedding Modeli Performans Analizi ve Vektör Arama Sistemi

1 Giriş

Bu çalışmada, verilen `golden_queries.json` veri seti üzerinde en yüksek performansı sağlayan embedding modelinin belirlenmesi amaçlanmıştır. Bu doğrultuda doğal dil sorguları vektör temsiline dönüştürülerek FAISS tabanlı bir vektör arama sistemi oluşturulmuş ve farklı embedding modelleri karşılaştırılmıştır.

2 Kullanılan Teknolojiler

- Python
- FAISS (vektör veritabanı)
- FastAPI (backend)
- HTML/CSS/JS (frontend)
- HuggingFace Sentence Transformers

3 Sistem Mimarisi

Sistem aşağıdaki adımlardan oluşmaktadır:

1. JSON veri setindeki sorular okunur.
2. Sorular embedding modele verilerek vektörlere dönüştürülür.
3. Vektörler FAISS veri tabanına kaydedilir.
4. Kullanıcıdan gelen sorgu embedding'e dönüştürülür.
5. En yakın vektör bulunarak ilgili JSON çıktısı gösterilir.

4 Kullanılan Modeller

- intfloat/multilingual-e5-large (Referans)
- paraphrase-multilingual-MiniLM-L12-v2
- BAAI/bge-m3
- emrecan/bert-base-turkish-cased
- dbmdz/bert-base-turkish-cased
- Gemini Embedding (Cloud - Mock)

Cloud tabanlı model API limitleri nedeniyle kapsamlı benchmark testlerine dahil edilmemiştir. Free tier kısıtlamaları sebebiyle her 100 sorguda 62 saniyelik bekleme uygulanmıştır.

5 Benchmark Sonuçları

Model	Accuracy (%)	Latency (ms)	RAM (MB)	CPU (%)
e5-large	95.6	23.13	449	20.0
MiniLM	76.8	13.28	1209	11.2
bge-m3	94.8	22.84	817	7.5
Emrecan BERT	75.0	19.63	990	1.0
DBMDZ BERT	80.0	19.05	991	3.8

Tablo 1: Modellerin genel performans karşılaştırması

6 Tekil Sorgu Analizi

Aynı sorgu için modellerin verdiği benzerlik sonuçları aşağıdaki gibidir:

- e5-large: %89.91
- bge-m3: %72.19
- MiniLM: %9.85
- Emrecan BERT: %0.21
- DBMDZ BERT: %0.35
- Gemini (Cloud): %89.91

Gemini modeli cloud tabanlı olmasına rağmen tekil sorgu testlerinde yüksek benzerlik değeri üretmiştir. Özellikle referans model ile benzer sonuçlar verdiği gözlemlenmiştir. Ancak API kullanım limitleri nedeniyle geniş kapsamlı benchmark testlerine dahil edilememiştir.

Bu sonuçlar, bazı modellerin belirli sorgularda ciddi performans kaybı yaşayabildiğini göstermektedir. Özellikle genel benchmark sonuçları yüksek görünen bazı modellerin tekil sorguda düşük benzerlik üretmesi, model seçiminde sadece ortalama başarı oranının değil sorgu bazlı tutarlılığın da önemli olduğunu göstermektedir.

7 Kararlılık (Stability) Analizi

Modeller, veri setine noise eklenerek tekrar test edilmiştir:

Model	Normal (%)	Noise (%)
e5-large	95.6	97.2
bge-m3	94.8	95.2
MiniLM	76.8	78.2
Emrecan BERT	75.0	74.0
DBMDZ BERT	80.0	73.2

Tablo 2: Noise etkisi altında model performansı

Sonuçlar, multilingual modellerin veri bozulmalarına karşı daha dayanıklı olduğunu göstermektedir. Özellikle e5-large ve bge-m3 modelleri noise sonrası performanslarını büyük ölçüde korumuş, DBMDZ BERT modelinde ise belirgin bir düşüş gözlemlenmiştir.

8 Model Performans Analizi ve Görselleştirme

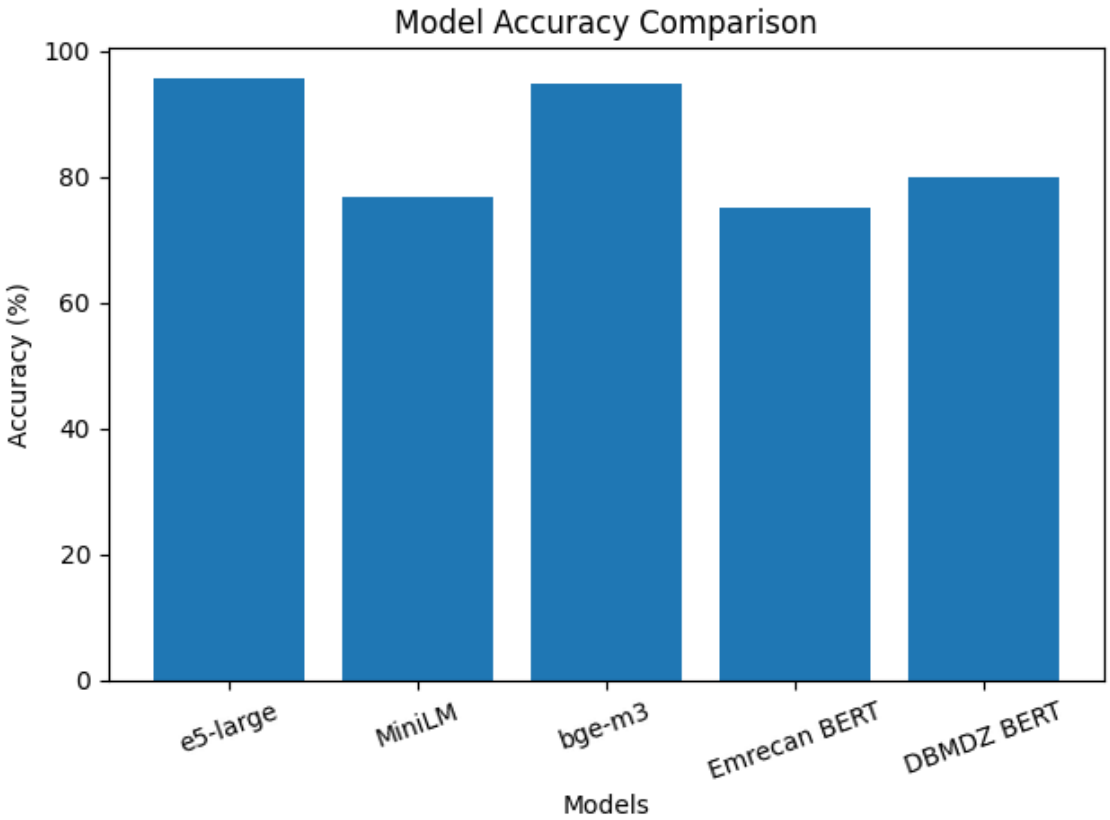

Şekil 1: Modellerin doğruluk (accuracy) karşılaştırması. Multilingual modellerin belirgin şekilde daha yüksek performans gösterdiği görülmektedir.

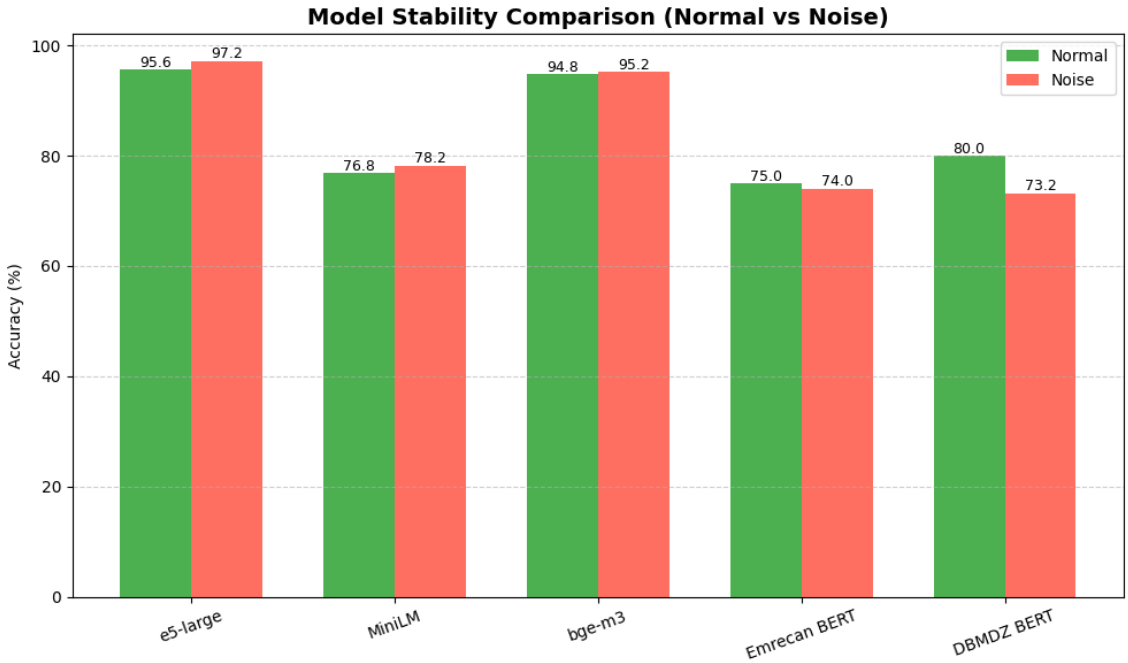

Şekil 2: Normal ve noise veri altında model performans karşılaştırması. Multilingual modellerin stabil kalırken bazı modellerin ciddi performans kaybı yaşadığı gözlemlenmiştir.

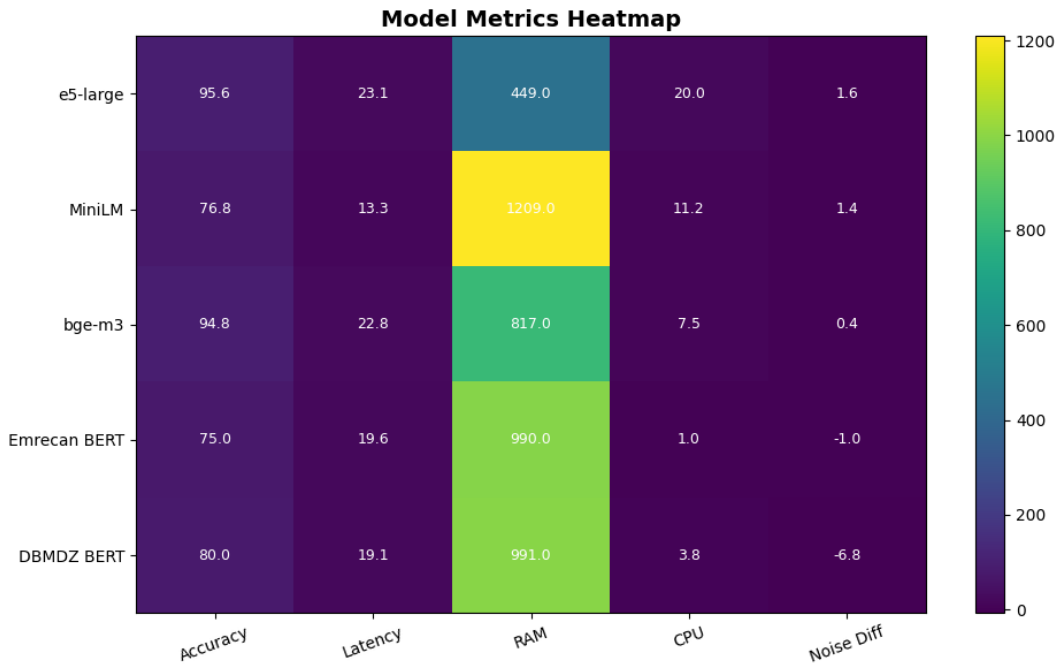

Şekil 3: Tüm metriklerin birlikte gösterildiği ısı haritası. Modellerin güçlü ve zayıf yönleri tek bakışta analiz edilebilmektedir.

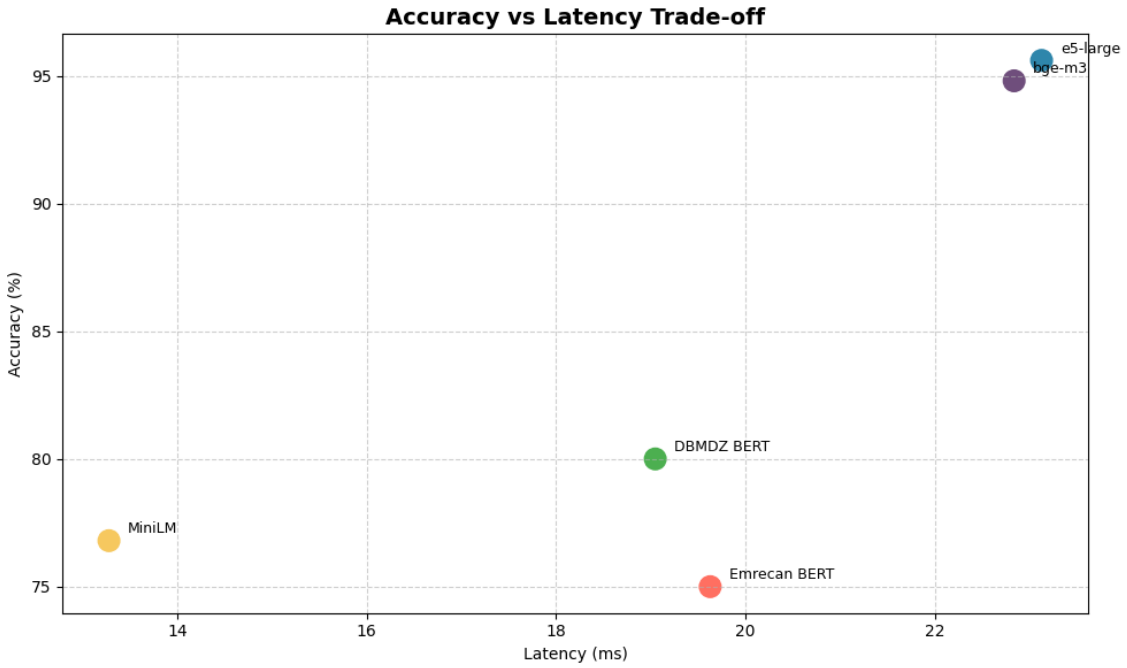

Şekil 4: Accuracy ve latency arasındaki dengeyi gösteren grafik. Yüksek doğruluk sunan modellerin genellikle daha yüksek gecikmeye sahip olduğu görülmektedir.

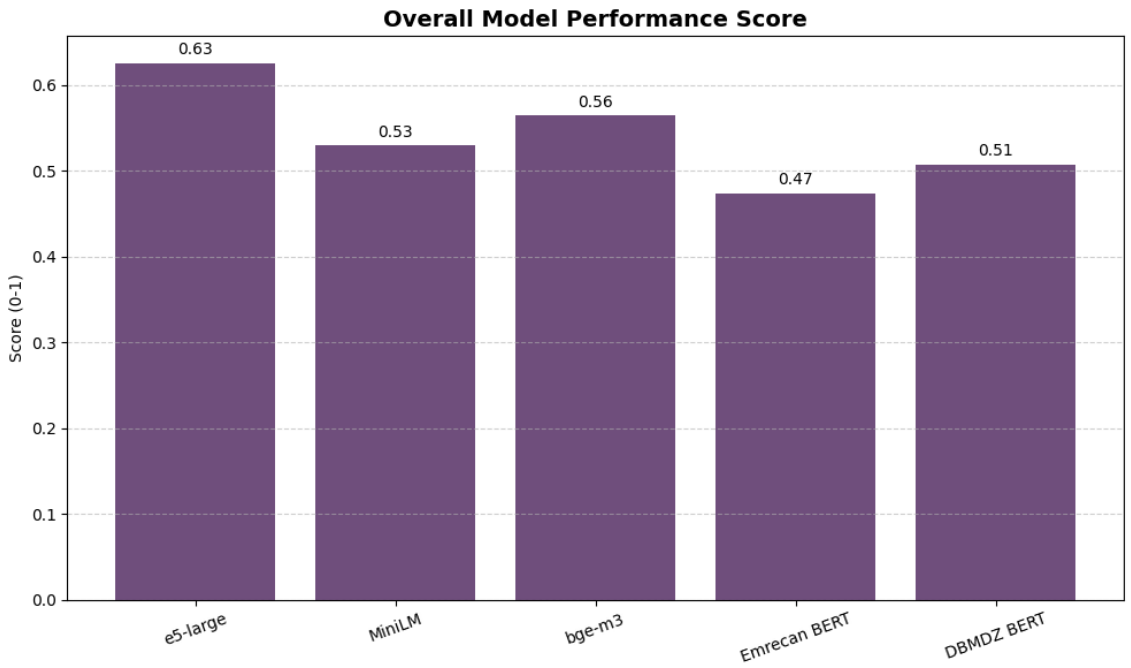

Şekil 5: Tüm metriklerin birleşimi ile elde edilen genel performans skoru. En yüksek skoru alan model en uygun aday olarak öne çıkmaktadır.

Grafik analizleri incelendiğinde, intfloat/multilingual-e5-large modelinin hem doğruluk hem de stabilite açısından en dengeli performansı sunduğu görülmektedir. BAAI/bge-m3 modeli benzer doğruluk değerlerine ulaşsa da daha yüksek kaynak tüketimi ve latency

değerleri ile ikinci sırada yer almaktadır. MiniLM modeli düşük gecikme süresi ile öne çıksa da doğruluk açısından yeterli sonuç üretememiştir.

9 Model Avantaj ve Dezavantaj Analizi

- **e5-large**
  - Avantaj: En yüksek doğruluk ve stabil performans
  - Dezavantaj: Görece daha yüksek latency
- **bge-m3**
  - Avantaj: Yüksek doğruluk
  - Dezavantaj: Yüksek RAM kullanımı
- **MiniLM**
  - Avantaj: Düşük gecikme süresi (latency)
  - Dezavantaj: Düşük doğruluk oranı
- **BERT Tabanlı Modeller**
  - Avantaj: Türkçe dil yapısına uygunluk
  - Dezavantaj: Düşük genel performans ve stabilite
- **Gemini (Cloud Model)**
  - Avantaj: Tekil sorgu testlerinde yüksek benzerlik oranı (referans modele yakın sonuçlar)
  - Dezavantaj: API limitleri nedeniyle kapsamlı benchmark yapılamaması
  - Dezavantaj: Latency ve kaynak tüketimi ölçümlerinin yapılamaması

10 Değerlendirme

Testler sonucunda aşağıdaki çıkarımlar yapılmıştır:

- e5-large modeli en yüksek doğruluk ve stabiliteyi sağlamıştır.
- bge-m3 modeli benzer doğruluk sunmakla birlikte daha fazla kaynak tüketmektedir.
- MiniLM modeli hızlıdır ancak doğruluk açısından yetersizdir.
- Türkçe BERT modeller düşük performans göstermiştir.
- Gemini modeli tekil sorgu testlerinde güçlü sonuç vermiştir; ancak benchmark verisi olmadığı için doğrudan genel karşılaştırmaya dahil edilmemiştir.

11 Sonuç ve Öneri

Yapılan analizler sonucunda, sistem entegrasyonu için en uygun modelin **intfloat/multilingual-e5-large** olduğu belirlenmiştir. Bu model, yüksek doğruluk oranı, kabul edilebilir gecikme süresi, düşük RAM tüketimi ve noise'a karşı dayanıklılığı ile diğer modellere kıyasla daha başarılı performans göstermiştir.

Alternatif olarak **BAAI/bge-m3** modeli değerlendirilebilir. Bu model de yüksek doğruluk sunmakta, ancak kaynak tüketimi açısından referans modele göre daha maliyetli bir yapı sergilemektedir.

Cloud tabanlı Gemini modelinin ise uygun API erişimi ve daha geniş test imkânı sağlanması durumunda gelecekte ayrı bir benchmark sürecine dahil edilmesi önerilmektedir.